

有效算力 vs 序列长度 (D=128, fp16, causal)

柱注: Ours/Native 效率比

